ЛЕКЦИЯ 12. Сравнение моделей: AIC, BIC и как выбрать лучшую

Введение

К этому моменту вы построили уже не одну регрессионную модель.

Вы научились:

- выбирать переменные,
- применять регуляризацию (Ridge, Lasso),
- следить за значимостью и простотой модели,
- анализировать R², остатки, коэффициенты.

Но когда вы создали несколько моделей, возникает вопрос:

"А какая из них лучшая?"

- Та, у которой выше R²?
- Та, у которой меньше переменных?
- Та, у которой коэффициенты "логичнее"?

Выбор не всегда очевиден.

Иногда одна модель объясняет больше, но сложнее.

Другая — проще, но чуть менее точна.

Чтобы сравнивать модели **объективно**, используются специальные метрики:

AIC и BIC.

Что такое AIC и BIC?

Это критерии качества модели, которые:

- учитывают точность модели,
- штрафуют за лишние переменные,

• помогают сравнивать модели с разным числом факторов.

AIC (Akaike Information Criterion)

- Чем ниже АІС, тем лучше модель
- Баланс между точностью и простотой
- Наказывает за "перегруженность"

BIC (Bayesian Information Criterion)

- Похож на АІС, но штрафует сильнее
- Больше подходит, когда у вас много наблюдений
- Тоже: **меньше = лучше**

Принцип работы

Формулы (упрощённо, без логарифмов):

```
AIC = -2 * логарифм правдоподобия + 2 * k BIC = -2 * логарифм правдоподобия + k * log(n)
```

Где:

к — количество параметров модели (включая свободный член),

n — количество наблюдений

Главное — **не считать вручную**, а сравнивать результаты, которые дают системы анализа (например, Python или R).

Как сравнивать

| Модель | AIC | BIC | Вывод |
|------------|-------|-------|--------------------|
| Модель 1 | 128.3 | 134.2 | Точнее, но сложнее |
| Модель 2 | 130.1 | 131.5 | Проще, менее точна |
| Победитель | 128.3 | 134.2 | AIC → модель 1 |

💪 Пример из курса

Гипотеза: успеваемость зависит от сна, стресса, и мотивации.

Выстроили 2 модели:

- Модель А: сон + стресс
- Модель В: сон + стресс + мотивация

| Модель | R ² | AIC | Вывод |
|--------|----------------|-------|-----------------------------------|
| Α | 0.68 | 145.2 | Простая, но не самая точная |
| В | 0.75 | 140.6 | Чуть сложнее, но заметно лучше |



У Вывод: модель В — предпочтительнее (ниже AIC)

Почему AIC лучше, чем просто R²

| Показатель | Что делает | Проблема |
|----------------|-------------------------------------|---|
| R ² | Считает, сколько объясняется | Всегда растёт при добавлении переменных |
| AIC | Балансирует точность и сложность | Может быть выше у "перегруженной" модели |
| BIC | Делает то же, но строже | Предпочитает простоту |

Где получить AIC и BIC?

| Среда | Поддержка |
|-------------------------------|--|
| Python (sklearn, statsmodels) | √ Да |
| R | √ Да |
| Excel, Google Sheets | ★ Нет напрямую, но можно обсчитать вручную (сложно) |

В рамках курса можно:

- сравнить R² и количество переменных,
- визуально обсудить: "Что проще?", "Что переобучено?",
- объяснить идею AIC и BIC как логики выбора, а не только цифры.

ИИ-поддержка

| Инструмент | Что делает |
|---------------|---|
| ChatGPT | Объясняет разницу между AIC и BIC |
| Excel Copilot | Помогает визуализировать сравнение моделей |
| Notion Al | Формулирует вывод о том, почему выбрана конкретная модель |

О Запрещено:

- Опираться только на R² для выбора модели
- Игнорировать сложность модели (10 переменных ≠ лучше)
- Использовать AIC/BIC, не объяснив, что они значат
- Сравнивать модели с разным у (должна быть одна и та же цель)

Вывод

AIC и BIC — это не "магические числа".

Это инструменты, которые учат выбирать осознанно:

не просто "что лучше объясняет", а "что делает это экономно, ясно и честно".

Это уже мышление зрелого аналитика:

"Не просто построить модель, а выбрать лучшую из возможных."